

Optimizing TabPFN Inputs through LLM-Based Feature Selection

지승훈, 정준수, 김석진, 이민규, 임동혁

광운대학교 정보융합학부



Introduction

TabPFN은 사전학습에서 획득한 prior를 바탕으로, 추론 시 제공되는 학습 표본과 특징을 context로 활용한다. 따라서 제한된 context를 어떻게 구성하는지가 성능에 직접적인 영향을 미친다. Feuer et al.의 *Scaling TabPFN*에서는 sample sketching보다 feature selection이 TabPFN 성능에 더 큰 영향을 미치며, TabPFN이 tree모델보다 입력 feature 구성에 민감하다고 보고하였다. 이는 불필요한 특징을 제거하는 것이 TabPFN context optimization의 유망한 방향임을 시사한다. 하지만 기존 feature selection은 관측 데이터의 통계적 관계에 의존하므로 고차원 소표본 환경에서 안정적인 중요도 추정이 어려울 수 있다. Li et al.의 *Exploring Large Language Models for Feature Selection*에서는 LLM 기반 feature selection을 data-driven 방식과 text-based 방식으로 구분하고, LLM의 사전지식을 활용한 text-based 방식이 저차원 환경에서 경쟁력 있고 안정적인 결과를 보임을 확인하였다. 이에 본 연구는 두 선행연구를 바탕으로, LLM이 평가한 특징의 의미적 관련성이 기존 통계 기반 feature selection을 보완하고 TabPFN의 입력 context를 효과적으로 구성할 수 있는지 검증한다.

Objectives

Can adaptive LLM-based feature selection improve TabPFN performance in HDLSS settings?

1. Input Context Optimization

Feature selection이 TabPFN의 입력 context와 예측 성능에 미치는 영향을 검증한다.

2. Semantic Prior Contribution


전통적인 FS와 LLMFS를 비교하여 LLM으로 얻은 의미 정보의 추가 가치를 분석한다.

3. Semantic-Statistical Fusion

LLM의 의미 정보와 통계적 정보를 결합할 때, 높은 성능을 얻을 수 있는지 평가한다.

Method

Proposed Adaptive LLMFS Pipeline



Text-based LLMFS

$$S_j = \text{Norm}(r_j \times c_j)$$
$$\mathcal{F}_k^{\text{Text}} = \text{TopK}_j(S_j, k)$$

- r_j : feature relevance
- c_j : LLM reliability
- S_j : semantic prior
- k : 선택할 feature 수

Feature값을 LLM에 제공하지 않고 feature 이름과 과제 설명만으로 의미적 관련성을 평가한다.

LLM 관련도와 신뢰도를 결합한 Semantic prior를 기준으로 상위 k개 특징을 선택한다.

Hybrid LLMFS

$$D_j = \text{Rank}(\text{CrossFittedAUC}_j)$$
$$H_j(\alpha) = \alpha S_j + (1 - \alpha) D_j$$
$$\mathcal{F}_{k,\alpha}^{\text{Hybrid}} = \text{TopK}_j(H_j(\alpha), k)$$

내부 교차검증으로 k와 α를 결정

$$(k^*, \alpha^*) = \arg \max_{k, \alpha} \text{AUROC}_{\text{inner}}$$

Semantic prior와 cross-fitted AUC 기반 Data prior를 결합한다. 내부 교차검증에서 결합 비율 α와 특징 수 k를 선택하여 데이터별로 의미 정보와 통계적 근거의 반영 정도를 조정한다.

두 방식의 핵심 차이

방식	사용하는 정보	선택 점수	조정값
Text-based	특징 이름, 과제 설명	S_j	k
Adaptive Hybrid	의미 정보 + 학습 데이터	$H_j(\alpha)$	k, α

- $\alpha = 1$: Text-based LLMFS
- $\alpha = 0$: Data-only FS
- $0 < \alpha < 1$: Hybrid LLMFS


Text-based 방식은 feature명과 과제 설명만으로 feature를 선택하며, Hybrid 방식은 의미 정보와 학습 데이터의 통계적 근거를 결합한다. α는 Semantic prior의 반영 비율, k는 선택할 feature 수이며, 두 값은 내부 교차검증으로 결정한다.

Results

AUROC by Condition

Method	Colon 24	Colon Full	Golub 24	Golub Full	METABRIC 64	METABRIC Full	Mean
Adaptive Hybrid	0.8523	0.8989	0.9932	0.9915	0.6470	0.7570	0.8566
CatBoost-RFE	0.8375	0.8693	0.9983	0.9974	0.6311	0.7475	0.8469
NoFS	0.8295	0.8756	0.9898	0.9932	0.6385	0.7531	0.8466
Data-only	0.7932	0.8784	0.9932	0.9881	0.6444	0.7597	0.8428
Weighted Hybrid	0.7943	0.8477	0.9957	0.9957	0.6615	0.7588	0.8423
Text-only	0.8136	0.8443	0.9804	0.9949	0.6146	0.7638	0.8353
LASSO	0.7920	0.8852	0.9898	0.9932	0.6148	0.7348	0.8350
Random	0.8295	0.8625	0.9591	0.9813	0.6038	0.7371	0.8289
MI	0.7227	0.8693	0.9889	0.9923	0.6429	0.7340	0.8250

Mean AUROC




Adaptive Hybrid는 6개 실험 조건에서 평균 AUROC 0.8566을 기록해 전체 비교 방법 중 가장 높은 성능을 보였다. 이는 CatBoost-RFE(0.8469)와 NoFS(0.8466)보다 각각 0.0097, 0.0100 높은 결과이며, Colon의 Low-resource와 Full-sample 조건에서 모두 우수했다. 개별 조건에서는 다른 방법이 더 높은 경우도 있었지만 전체 평균은 Adaptive Quota Hybrid가 가장 높았다. 반면 Data-only, Weighted Hybrid, Text-only는 평균적으로 NoFS보다 낮았다. 이는 의미 정보나 통계 정보를 고정적으로 적용하기보다, 데이터에 따라 특징 수 k와 결합 비율 α를 조정하는 adaptive strategy가 전반적인 성능 향상에 기여했음을 시사한다.

AUROC Gain over NoFS

Data	Low-resource	Full sample
Colon	+0.0227	+0.0233
Golub	+0.0034	-0.0017
METABRIC	+0.0085	+0.0039

Adaptive Hybrid는 6개 조건 중 5개에서 NoFS보다 높은 AUROC를 보였으며, Colon에서 가장 크게 향상되었으며, METABRIC에서도 두 조건 모두 개선되었다. 다만 Golub의 Full-sample 조건에서는 성능이 소폭 감소하여, 특징 선택 효과가 데이터와 표본 수에 따라 달라질 수 있음을 확인하였다.



feature 수는 k=32가 14회로 가장 많이 선택되어 비교적 적은 수의 핵심 feature가 선호되었다. 의미 정보의 결합 비율은 α=0.75가 14회로 가장 많아, 통계 정보보다 LLM의 의미 정보를 높게 반영하는 구성이 주로 선택되었다. 다만 k와 α가 여러 후보에 분포한 결과는 데이터와 학습 표본에 따라 최적 설정이 달라지며, 고정된 설정보다 fold별 adaptive tuning이 필요함을 보여준다.

Discussion

Adaptive Hybrid는 6개 조건 중 5개에서 NoFS보다 높은 AUROC를 보였으며, 전체 방법 중 가장 높은 평균 AUROC를 기록하였다. 반면 Text-only와 Weighted Hybrid는 평균적으로 NoFS보다 낮아, LLM의 의미 정보를 단독 또는 고정된 비율로 결합하는 것만으로는 일관된 성능 향상을 보장하기 어려웠다. 내부 검증에서는 k값과 α값이 고루 분포되었으며 이는 최적 특징 수와 의미 정보 비율이 데이터와 학습 fold에 따라 달라지며, k와 α를 선택하는 전략이 TabPFN context optimization에 효과적일 수 있음을 보여준다.

Feature selection should be considered part of TabPFN context design rather than a simple preprocessing step. LLM-derived semantic information is valuable, and k and α should be adapted to each dataset.